

在没有逐小时监督的情况下学习连续败血症严重程度评分：一项两地点回顾性研究

Kevin Zhu^{1,3}, Ryan Zhang^{2,3}, Baraa Abed^{2,3}, Tilendra Choudhary, 博士^{3,4}, Malvern Madondo, 博士^{3,4}, Mehak Arora^{2,3}, Yixuan Yang^{2,3}, Alasdair Gent, 博士^{3,4}, Aditya Nagori, 博士^{3,4}, Omer T Inan, 博士^{5,6}, Krista L. Haines, DO^{3,7}, Patrick Georgoff, 医学博士³, Suresh M. Agarwal, 医学博士³, Vijay Krishnamoorthy, 医学博士, 博士^{4,7}, Tetsu Ohnuma, 医学博士, 博士, 公共卫生硕士⁴, Mihai V. Podgoreanu, 医学博士⁴, Michael R. Pinsky, 医学博士, CM, 名誉博士, FC CP, MCCM^{8,9}, Gilles Clermont, 医学博士, 理学硕士^{8,9}, Craig M. Coopersmith, 医学博士, FA CS, FCCM^{10,11}, Craig S. Jabaley, 医学博士, FCCM^{10,12}, Rishikesan Kamaleswaran 博士^{1,2,3,4}

1 杜克大学生物医学工程系, 北卡罗来纳州达勒姆。2 杜克大学电气与计算机工程系, 北卡罗来纳州达勒姆。3 杜克大学医学院外科系, 北卡罗来纳州达勒姆。4 杜克大学麻醉学系, 北卡罗来纳州达勒姆。5 乔治亚理工学院电气与计算机工程学院, 乔治亚州。6 乔治亚理工学院生物医学工程系, 乔治亚州。7 杜克大学医学院人口健康科学系, 北卡罗来纳州达勒姆, 美国。8 匹兹堡大学重症医学系, 宾夕法尼亚州。9 匹兹堡大学医学院, 宾夕法尼亚州。10 埃默里重症护理中心, 埃默里医疗, 乔治亚州亚特兰大。11 埃默里大学医学院外科系, 乔治亚州亚特兰大。12 埃默里大学医学院麻醉学系, 乔治亚州亚特兰大。

Abstract

目标：目前使用的败血症严重程度指数依赖于几十年前建立的固定变量和权重，这些变量和权重被粗略离散化，并校准于一个不再反映当代重症护理的队列。尚未有直接从患者轨迹中学习的替代方法被常规使用。

设计：一项回顾性两队列研究。

背景：位于马萨诸塞州和乔治亚州的两家医院系统。

患者：共有29,116名和7,691名符合Sepsis-3标准的成年患者，排除了可能的数据输入错误的异常值。

干预措施：无。

测量与主要结果：我们开发了一个每小时的脓毒症指数，使用在72小时治疗窗口内记录的43个常规变量。与以往研究不同，我们使用死亡率作为治疗层面的排名信号，而不是每个状态的目标，这允许积分在时间步之间非均匀地重新分配，而不是作为恒定标签向后传播。评估是在永久保留的20%测试集上进行的，使用临床病例模拟和斯皮尔曼相关性。通过对整个患者的自助重采样获得不确定性区间。在死亡率排名下，非幸存者在0–10分的量表上比幸存者高出1.19–1.64分，在所有四个基线SOFA-2分层中结果相似，对乳酸、平均动脉压（MAP）和肌酐分层结果也相似。患者内指数的变化与乳酸变化相关（斯皮尔曼 $\rho = 0.39$ ； $n = 1854$ ）；对MAP和肌酐也发现了类似但较弱的相关性。在队列层面，交叉-

结论：单纯从结果排序轨迹中学习的指标显示出每小时的预测信息，能够有意义地区分患者结果，并与临床预期一致，表明其作为补充临床判断的决策支持工具具有潜力。

。

Key Points

问题：是否可以直接从按患者结局排序的 ICU 住院数据中学习连续的、每小时的脓毒症严重程度指数，而无需共识分配的变量、权重或每小时的临床医生标注？

研究结果：在这项两地点回顾性研究中（MIMIC-IV, $n = 29,116$; Emory Healthcare, $n = 7691$ ），由上述顺序监督的指数能够在每个呈现严重程度的分层中区分生存者与非生存者，随着同期生理变化而变化，并在标签消融下失去其信号，尽管跨机构的一致性未达到机构内的上限。

含义：仅根据排名结果估算的严重性指数，在经过本地验证和前瞻性评估后，可能作为一种预后指标使用。

Introduction

败血症是由宿主对感染的失调反应引起的危及生命的器官功能障碍 [1]。它是全球死亡率最大的单一因素之一：《2021年全球疾病负担》分析估计，2021年全球败血症新发病例为1.66亿例，相关死亡人数为2140万例，占当年所有死亡人数的约31.5% [2]，且败血症存在于超过一半以死亡或转入临终关怀结束的成人住院病例中，并且在其中的三分之二病例中，败血症是直接死因 [3]。

在重症监护病房（ICU）中，一个常见的做法是使用严重程度评分，这是一种数值，用于衡量病情、损伤或系统故障的严重性、强度或关键影响[4]。用于此方法的一些最常用的评分包括连续器官衰竭评估（SOFA）[4]、急性生理与慢性健康评估 II（APACHE II）[5] 以及全身炎症反应综合征（SIRS）标准[6]。

尽管这些指数是根据不再反映当代重症护理的病例组合校准的，它们仍然是操作标准[7]。现代化的努力集中在更新其权重上：SOFA-2 根据当代结果重新校准器官功能障碍阈值 [8]，APACHE IV 在更新的队列上重新拟合死亡率系数[9]。由于采用障碍[8, 10]，它们都未在常规实践中取代其前身，但更重要的一点是，两者都保留了其前身建立的设计。每个指数都根据患者在单一时间点的状态与随后的死亡率之间的关联分配分数，每次计算时都作为独立评估应用。

机器学习的恶化模型能够产生更精细时间分辨率的估计，但突出的例子是对其监督进行逐点应用。诸如 DeepSOFA [11] 和 Thorsen-Meyer 等人 [12] 的动态死亡率模型等模型，对单个患者水平的结果进行每小时预测，因此最终非幸存者住院的每一个小时都会单独拟合

高风险，包括患者尚未恶化的时间段。时间到事件的公式[13]按接近终点的程度对时间进行加权，但目标仍然附着在每个时间点上。我们的监督来源于相同的结果，但仅约束一个窗口相对于另一个窗口的累积得分，而不限制该得分在各小时之间的分配。败血症是一种由其病程定义的疾病，在一个正在稳定的患者中，相同的生理状态与在向相同状态恶化的患者中所代表的意义不同；因此，我们提出的问题是，是否可以通过使用逆向强化学习（IRL）衍生的方法，从整个治疗窗口的相对顺序学习的严重程度指数，比单独监督的时间点序列更忠实地表示这种病程。

逆向强化学习（IRL）是强化学习（RL）的一个分支，其中智能体通过与环境的交互来学习某些最优行为[14]。在强化学习中，奖励函数定义了智能体在环境中优化的具体任务。例如，在导航任务中，奖励可以是与到达目的地的距离相关的负值。智能体距离目的地越近，奖励越高。这也可以应用于临床环境：对于脓毒症治疗任务，奖励可以是与患者存活可能性相关的某个值。在这种解释下，从历史实践中得出的奖励函数可以作为患者严重度评分。IRL的目标是通过专家轨迹学习这样的奖励。

因此，我们提出了一个通过这种逆向强化学习（IRL）方法之一——轨迹排序奖励外推（Trajectory-ranked Reward Extrapolation, T-REX）[15]（图1）学习的严重性指数。在两个独立的ICU队列中，我们根据三种基于结果的排序方案训练了该指数，并将其与已建立的严重性指数、自身的标签消融以及关于严重性应如何响应生理变化的临床预期进行了比较。该指数与SOFA-2、APACHE II和SIRS相关，并能够区分院内死亡率，与直接结果监督一样有效，而两个消融方案则没有任何信号。它还携带了超出入院状态的预后信息，在每个基线严重性层级中将幸存者与非幸存者区分开来，并随着患者住院期间的同期生理变化而变化。

Methods

Study Design

我们进行了一项回顾性试点研究，以开发和评估一种败血症严重程度评分，该评分直接从患者病程中学习，而不是从预先指定的变量和权重中组装而成。数据来自两个独立的ICU队列：MIMIC-IV（版本 3.1，贝斯以色列女执事医疗中心，2008–2022）[16]和 Emory Healthcare（2015–2022）。我们纳入了在ICU入院期间符合 Sepsis3 标准的 18 岁及以上成人（补充材料，数据处理）。本研究经杜克大学健康系统机构审查委员会审查批准，并被认定为免于审批。

IRBPro00114885。两个队列的人口统计学和临床特征总结见表1。

结果标签是一个出院处理情况，将临终关怀出院计为死亡，遵循美国败血症死亡率流行病学中使用的终点 [3]，在埃默里患者中发生率为23.7%，在MIMIC-IV患者中为15.1%。在每个医疗机构中，20%的患者被作为永久测试保留（1,538名埃默里患者和5,823名MIMIC-IV入院病例），按死亡率分层，并且从未用于训练或模型选择。其余患者被分为四个按死亡率分层的折叠组（患者在训练过程中从未见过的分区），每一折轮流作为验证集，而其余三折用于训练。治疗窗口跨度最长为72小时，从败血症发生前24小时到发生后48小时，我们收集了四十三个生理、实验室和治疗变量（补充材料，表S1）。

Data Processing

按照 Arora 等人 [17] 的方法，患者的观察数据按小时汇总，并截断到生理上合理的范围内。缺失值在每次入院期间通过前向填充进行插补，剩余的缺失值则使用训练分区的相应中位数进行插补。

Score Development

我们遵循了 T-REX 的训练方法，使用多层感知器来学习严重程度评分（补充材料，算法 1）[15]。T-REX 使用一种排序方案来比较患者住院期间的成对记录；我们比较了总共三种方案，我们称之为 *mortality*、*mortality-plus-treatment* 和 *severity-matched*。*Mortality* 更倾向于生存者而非非生存者。*Mortality-plus-treatment* 在生存者和非生存者组内增加了治疗强度作为决胜因素。治疗窗口内血管加压药累积剂量较低的患者住院记录优于剂量较高的患者；如果患者在生存状况和血管加压药剂量上相同，则使用治疗窗口内给予的累计液体量来破平局。这体现了临床原则，即在生存的条件下，较低的有效剂量是优选的。最后，*severity-matched* 更倾向于生存者而非非生存者；然而，只有当两条轨迹都位于相同的年龄、基线乳酸和基线改良 SOFA-2 分组中时，才会比较它们的一对轨迹。这是 d

Ablation Studies

对于每种排序方案，都构建了两个消融实验，并以与真实模型相同的方式进行训练。在 *shuffled* 消融实验中，训练时有 50% 的偏好对被反转。在 *random* 消融实验中，偏好标签是随机的。由于这些模型共享真实模型的架构、输入特征和数据几何，仅在偏好标签上有所不同，因此它们限制了任何报告效果在没有可学习偏好信号的情况下可能产生的程度。

Evaluation

由于不存在可以直接对学习索引进行评分的真实严重性标签，我们沿两个轴线间接评估了该索引：预后信息内容和学习索引的临床有效性。基线分层轨迹分析（补充材料，评估方法1）用于确定索引是否能在呈现状态的分层中区分存活者与非存活者。患者内响应分析（补充材料，评估方法2）比较了每位患者窗口内索引的变化与生理变化的同步变化。配对跨机构评分（补充材料，评估方法3）应用于每位未纳入的患者，以评估评分生成方法的外部有效性。额外测试包括将学习索引与既有严重性评分进行比较以及学习的稳健性（补充材料，评估方法4），以及对一种方法的性能进行评估。

为了评估临床适用性，强调两个目标：1）提供超出患者当前状况的预后信息；2）提供在其训练所在机构之外仍可解读的每小时读数。此外，提出了一个两部分的评估：首先，确保指标的结果区分不是基线严重程度的重复陈述；其次，评估指标变化与同时的生理变化之间的一致性，以确认与临床预期的符合性。

斯皮尔曼相关（标记为 ρ ）在 Fisher z 空间中平均，包括每个自助法（bootstrap）重复中的相关。通过对整个患者进行自助法重采样获得不确定区间；所有区间均为固定随机种子的 95% 百分位区间，根据所需计算量，从 1000 次或 200 次重复中计算得出。

Results

Model Selection

在评估的排名方案中，死亡率方案被选为最终的评估模型。选择该模型的原因是所有方案与已建立的严重程度指数的相关性相似，而死亡率方案使用了最简单的排名方法，并且在不同随机种子和数据折叠间的重复实验中达到了最高的一致性。

Patient Stratification

图 2 显示了 MIMIC-IV 中从败血症发作开始随时间变化的学习评分，分别针对幸存者和非幸存者，在由每位患者前 24 小时的最严重 SOFA-2 定义四个基线疾病严重程度层中。分组为 ≤ 3 ($n = 1045$)、4-5 ($n = 2016$)、6-7 ($n =$

1475), 以及 ≥ 8 ($n = 1287$), 院内死亡率分别为 9.3%、8.9%、15.0% 和 29.5%。该评分采用固定的0–10尺度, 方向设定为分数越高表示病情越重, 每条曲线是基于MIMIC-IV训练的20个模型平均形成的共识评分在患者群体上的均值。非幸存者与幸存者之间的平均差距, 在抽取的各个时间段取平均后, 四个分层中分别为1.19、1.42、1.36和1.64分, 因此在每个呈现严重程度的水平上都存在区分, 而不是集中在最重病的患者中。基于基线乳酸水平分层的相同图表见补充资料(图S1), 对于 < 2 、 $2-4$ 和 > 4 mmol/L的分箱分别给出了1.48、1.73和1.66分的差距, 第四个分层为前24小时未测乳酸的患者, 其分差为1.33分。在埃默里大学的八个分层中, 该差距同样为正值, 平均动脉压(MAP)和肌酐也显示了类似结果(补充资料)。

Comparison Against Physiology

图3探讨了学习得分是否会随着患者在其自身住院期间的生理状态而变化, 而横断面响应曲线无法确定这一点。对于每位被保留的MIMIC-IV患者, 在治疗窗口的前后 k 小时之间的得分变化, 与同一时间段内三个变量的变化进行比较, 其中仅在两个时间段变量均被测量且未进行插补的患者才被纳入。得分的变化跟踪乳酸的变化(Spearman 0.39; $n=1,854$), 并且在那些自身基线乳酸已较高的患者中最为明显, 从0.25升至0.55。平均动脉压(MAP)的升高会导致得分下降, 这一效应在入院时低于65 mmHg的患者中最强, 在高于85 mmHg的患者中最弱。肌酐的变化仅通过Spearman相关与得分变化相关。与乳酸相比, MAP和肌酐的关联性要弱得多。

Cross-Institutional Performance

图4在单个患者的时间进程层面上提出了迁移问题: 当在一个机构训练的模型和在另一个机构训练的模型对同一名未用于训练的患者进行评分时, 这两组序列的表现是否相似? 对于每一名未用于训练的患者, 在MIMIC训练的模型和在Emory训练的模型的一致性在该患者自身的各个小时之间是相关的。在MIMIC-IV患者中, MIMIC-IV训练的模型与Emory训练的模型之间的中位数患者内Spearman相关系数为0.54 (95% 置信区间, 0.53–0.55), 在Emory患者中为0.59 (0.56–0.61), 而机构内的上限分别为0.92和0.90。两个负对照限定了另一端。然而, 一致性仍然分布广泛, MIMIC-IV的四分位数范围为0.20到0.76, Emory为0.27到0.79, 并且有14.2%和12.7%的患者返回了负相关。两组评分都在相同的未用于训练的状态上进行了标准化, 这通过构造将每条序列的平均值固定为零; 仅比较排名和

Comparison of Ranking Schemes

图5显示了一个合理性检查：三个排序方案与MIMIC-IV中的四个既定严重性指标之间的一致性。Emory小组和完整的方案-指标网格在补充材料中。在排序方案与指标的十二种组合中，分数与严重性指标之间的平均斯皮尔曼相关系数在MIMIC-IV中介于0.25到0.46之间，在Emory中介于0.18到0.59之间。两种消融实验接近零：在每个站点的24个随机偏好和随机标签条件下，没有平均相关系数的绝对值超过0.08。在四个指标之间的一致性排序在所有六种排序方案与站点的组合中都是相同的：与包含年龄的APACHE II最高，其次是不包含年龄的APACHE II，再次是SOFA-2，最低的是SIRS。

独立训练的复制模型之间的学习评分一致性随扰动程度的增加而单调下降，从随机种子到交叉验证折，再到机构变化。对于死亡率方案，仅在随机种子上不同的模型在Emory的平均斯皮尔曼相关为0.79，在MIMIC-IV中为0.78。更换交叉验证折几乎没有影响，而更换机构影响显著，使一致性降低到0.63和0.56，分别保留了对应机构内一致性的77%和70%。死亡率加治疗和严重度匹配方案呈现类似的趋势。将治疗强度加入排序降低了该梯度的两端：仅随机种子不同的模型在Emory的一致性为0.51，在MIMIC-IV为0.67，而在不同机构训练的模型分别为0.44和0.38。严重度匹配也降低了模型性能，但程度没有那么大（补充材料）。

Mortality Discrimination Against Controls

入院时对院内死亡率的区分能力进行了评估，在治疗窗口的前24小时内，相对于空消融和方法学基线。两种消融几乎完全丧失了所有信号：在排名方案和两个站点中，打乱和随机条件下每个模型的中位AUROC在0.486到0.533之间，而在MIMIC-IV中为0.764，在Emory的死亡率方案中为0.742。

作为其20个模型的共识，死亡率评分与在两个站点分别针对死亡率逐点训练的基线神经网络共识集成匹配：在MIMIC-IV中为0.791对0.789（Spearman 0.74），在Emory为0.765对0.768（0.43）。各个单独模型比基线略低但稳定（中位差异：MIMIC-IV为-0.017，Emory为-0.022）。完整的排序方案、消融实验和比较表格在补充材料中。

Discussion

这项试点研究调查了一个完全由排名轨迹构建的指标是否表现得足够像严重程度评分，从而值得将其开发为正式评分。我们的初步发现表明，基于偏好的奖励学习方法，例如 T-REX，为脓毒症提供了一条有前景的途径，可以创建一个连续的、每小时更新的严重程度指数，该指数是通过结果排序轨迹的相对顺序学习而来，而不是通过横断面的死亡率关联来确定，无论这些关联是通过专家共识（如 SOFA 中）编码，还是通过回归系数四舍五入到整数点数（如 SAPS II 和 APACHE III 中）。在每个呈现严重程度层级中幸存者与非幸存者之间的区分表明，这种评分可以在比每日一次评分更细的时间尺度上提供与结果相关的信息。对患者自身变化的方向性反应，包括乳酸升高时的变化，表明该指标能够跟踪临床医生关注的生理状态。然而，在一个

我们的评分与既定的严重程度指数不同，区别在于它的学习方式，以及与先前报道的学习评分相比，其输入范围更广。传统指数根据患者在单一时间点的状态与随后的死亡率之间的关联来分配校准得分；更频繁地计算此类指数会产生一系列独立的横断面评估，每次评分都不参考其周围的时间段。我们的指数则是拟合到一个定义在整个治疗窗口上的目标，并按结果进行排名，因此监督约束累积分数跨越整个窗口，而不是将终点标签附加到其中的每个状态。尽管在推理时学习的奖励是逐点评估的，这种训练信号允许最终未存活者在早期小时的评分偏低而不受惩罚，只要整个窗口相对于存活者的顺序正确即可。

因为它依赖于套广泛且部分重叠的生理信号，而不是一个小型的固定面板，所以不需要单一测量即可产生评分：在治疗窗口的前24小时内没有乳酸值的5,823名MIMIC-IV患者中，有1,632名（28.0%）仍可计算该评分，这一子群的患者传统指标中依赖乳酸的组成部分是未定义的。将每位患者的窗口开始和结束进行比较，评分的变化方向符合临床预期，即乳酸升高时评分上升，平均动脉压（MAP）恢复到名义范围时评分下降，肌酐升高时评分排名上升（图3）。在队列水平上，从起病开始到基本每小时，幸存者和非幸存者在呈现严重程度的每个层次中都有明显区分（图2），这表明每小时的估算反映的信息并非完全由呈现时的严重程度所捕捉。

解释该评分时，一个关键考虑因素是它是从实际提供的护理中学得的，因此反映了它训练的队列的治疗模式。这在其对血肌酐变化的反应中是可见的，其中在患者中 Spearman 相关系数由 ρ 增强至 $= 0.09$ 。

基线肌酐低于1.2 mg/dL的患者在1.2–2.0 mg/dL范围内下降至0.19，然后在高于2.0 mg/dL时降至0.06，区间跨越零。在肌酐升高应该最具权重的层次中，该评分在很大程度上停止了跟踪它；这与乳酸形成对比，乳酸随严重程度增加表现出单调递增的相关性。Caruana 等人描述了这种模式，在一个肺炎风险模型中发现哮喘是保护因素，因为哮喘患者接受了更积极的治疗并获得了更好的结果：一个拟合于观察结果的模型同时编码了对治疗的反应和疾病本身。我们的状态空间无法将二者分开，因为我们的43个输入中不包含血管加压药、液体、肾脏替代或机械通气变量。因此，我们当前的评分无法区分肌酐高且未治疗的患者与已经接受肾脏支持的患者。未来的迭代

该评分在不同机构之间的泛化能力是有限的，这种界限取决于偏好是如何排序的。随着扰动从随机种子到交叉验证折叠再到机构变化的增长，独立训练的模型之间的一致性单调下降，并且在死亡概率方案下，它保留了大部分在机构内部的一致性。将治疗强度加入排序会降低这一梯度的两端；因此，该方案不仅仅是在转移时更难，而是在单一站点内的可重复性也较差，而无需考虑任何分布变化。这一现象的一个潜在解释是，血管加压药和液体暴露记录了特定病区对病情恶化的反应，而不是患者的状态，因为剂量、时间和阈值可能因病区而异。在治疗暴露能够作为可转移的排序信号之前，需要以一种不依赖具体规范的形式来表达。

在单个患者而非模型对之间进行测量时，MIMIC-IV 训练的评分与埃默里训练的评分之间的中位数一致性远低于它们在各自机构的上限。一个显著的局限性是，每个机构中都有非忽略不计比例的患者，其两个评分对其时间排序的方向相反。对于这些患者，在不同队列上训练的评分可能会高估或低估其真实严重程度。在第三个机构进行前瞻性评估，并进行本地重新校准，可以确定这一残余差距可以减少到何种程度。

学习严重性指数作为一种回顾性分析工具，仅使用常规记录的变量为患者状态分配每小时的严重性值，无需共识分配的权重或手动评分。由于各机构之间的一致性低于机构内部的上限，这项工作的下一阶段将涉及在其他健康系统中进行回顾性验证并进行本地重新校准，然后进行安全性和可用性的前瞻性评估。将其作为现有电子健康记录系统中持续更新的显示集成，代表了临床实施的实际途径。此外，由于其基础方法源自逆向强化学习（IRL），该评分可用于训练未来临床决策支持系统的强化学习算法，例如用于建议血管加压药或液体剂量的系统。

Conclusions

在这项初步研究中，我们展示了基于偏好的逆强化学习（IRL）可以应用于脓毒症严重程度评估，从常规记录的数据中获得一个连续的小时指数。我们利用 T-REX 和基于结果的脓毒症治疗窗口排名来学习一个严重程度指数，该指数能够在每个呈现严重程度的分层中区分存活者与非存活者，并随着每位患者在住院期间自身生理状况的变化而变化。与已有的严重程度指数以及训练于死亡率的点对点网络相比，该指数至少在同等水平上区分了院内死亡率，尽管不同机构之间的一致性未达到机构内部的一致性上限。我们的研究表明，经过结果排名的轨迹学习可以补充由专家制定的脓毒症评分，但需要在床边使用之前进行本地验证。

Tables and Figures

表 1: 研究人群的人口学特征

Characteristic	Emory (n = 7,691)	MIMIC (n = 29,116)
Age (y), mean (std)	61.7 (16.6)	63.9 (16.3)
Sex, n (%)		
Female	3,556 (46.2)	12,468 (42.8)
Male	4,135 (53.8)	16,648 (57.2)
Race, n (%)		
White	3,362 (43.7)	19,439 (66.8)
Black or African American	3,601 (46.8)	3,049 (10.5)
Hispanic or Latino	—	1,111 (3.8)
Asian	253 (3.3)	879 (3.0)
American Indian or Alaska Native	—	61 (0.2)
Native Hawaiian or Other Pacific Islander	—	41 (0.1)
Other	—	989 (3.4)
Unknown	475 (6.2)	3,547 (12.2)
Hospital length of stay (d), median [IQR]	10.6 [6.0, 18.9]	9.2 [5.6, 16.0]
In-hospital death or hospice discharge, n (%)	1,824 (23.7)	4,391 (15.1)




图1：严重

程度指数流程概览。从电子健康记录（EHR）中提取的每小时生理和实验室数据输入模型，该模型应用由多达72小时脓毒症治疗时段的结果排序指导的轨迹排序奖励外推（T-REX），而不是按每小时临床医生标签。网络学习在24小时段内，为获得更好结果的住院患者赋予较低的累计评分，这里显示的是两名在基线严重性上匹配但死亡率不一致的患者。其结果是一个基于现代实践学习而非共识制定的连续每小时严重程度指数。在此尺度上（从0到10），5表示所有脓毒症ICU患者小时的平均严重程度，数值越高表示严重程度越高。MAP = 平均动脉压，NEE = 去甲肾上腺素等效量，SOFA-2 = 连续器官衰竭评估版本2。




图 2：在 MIMIC-IV 数据中，败血症发作后 48 小时内的学习严重性评分，根据每位患者在前 24 小时内最严重的 SOFA-2 评分，将基础严重性分为四个层级。顶排图显示幸存者（蓝色）和非幸存者（橙色）的平均评分，以及来自 1,000 次整体患者自助重采样的 95% 百分位区间；曲线仅在至少 25% 的该结果组贡献状态的小时内绘制。底排图显示每个层级中的一名幸存者和一名非幸存者，三角形标记血管加压药开始时间。评分为固定 0–10 量表；分数越高病情越重，基于 20 个在 MIMIC-IV 上训练的模型（4 折交叉验证 × 5 个随机种子）。




图3：同一患者住院期间学习到的严重性评分变化与三种生理变量变化的关系，在由死亡率排序模型评分的未使用MIMIC-IV患者中。每个点代表一名患者。左列为所有患者的散点图；之后的列按患者基线值进行分层。垂直轴为冻结的0-10评分点数，并在各面板间共享。每个面板显示患者数量（n）和斯皮尔曼相关系数（ ρ ），既显示整体队列，也按严重程度分层。蓝色表示存活者，橙色表示非存活者。Emory的类似图表见补充资料。




图4：在单

个保留患者中，MIMIC-IV训练模型与Emory训练模型之间的一致性。A：随机选取的八名患者，每个机构按结果分类每类两名。每个患者由20个Emory训练模型（蓝绿色）和20个MIMIC-IV训练模型（红紫色）打分两次。线条表示各训练站点模型的共识，带状区域表示各模型的2.5-97.5百分位。横轴为从败血症发生开始的小时数，虚线表示发生时间；纵轴为冻结的0-10评分，数值越高表明病情越严重。B：每个机构中两系列之间的患者内Spearman相关的累计分布：跨机构（橙色）、机构内部基于各站点模型10对10拆分的上限（天蓝色）、异地打乱（深灰色）和同站点打乱（浅灰色）负对照。横轴上的刻度标出A中八名患者的位置。




图5：在MIMIC-IV中，学习得分与四个已建立的严重度指数之间的一致性，通过模型每个状态得分与取负的指数之间的Spearman等级相关系数来衡量。箱体表示四分位距；中线为中位数，须状线延伸到最小值和最大值，20个模型均以点的形式绘制。白色菱形为在Fisher z空间中对每个条件的20个模型取平均值。面板为四个指数，每个面板中的每个排名方案均显示其两个负对照。埃默里大学的结果在补充材料中。APACHE II APS = APACHE II 急性生理评分，未包括慢性健康点；APACHE II APS + 年龄 = 同一评分包含年龄点。

References

1. Singer, M. *et al.* 第三次国际共识对脓毒症和脓毒性休克的定义 (sepsis-3)。 *JAMA* 315, 801–810 (2016)。
2. Gray, A. P. *et al.* 全球、地区和国家级脓毒症发病率和死亡率, 1990–2021: 系统分析。 *The Lancet Global Health* 13, e2013–e2026 (2025)。
3. Rhee, C. *et al.* 美国急诊住院中脓毒症相关死亡的患病率、潜在原因及可预防性。 *JAMA Network Open* 2, e187571 (2019)。
4. Vincent, J.-L. & Moreno, R. 临床综述: 重症病人的评分系统。 *Critical Care* 14, 207 (2010)。
5. Knaus, W. A., Draper, E. A., Wagner, D. P. & Zimmerman, J. E. APACHE II: 疾病严重程度分类系统。 *Critical Care Medicine* 13, 818–829 (1985)。
6. Bone, R. C. *et al.* 脓毒症和器官功能衰竭的定义, 以及脓毒症创新疗法使用指南: ACCP/SCCM共识会议委员会。 *Chest* 101, 1644–1655 (1992)。
7. Soares, M. & Dongelmans, D. A. 为什么我们不应该使用APACHE II